



دانشکده علوم ریاضی

**در برابر انسداد موضعی و ResNet-۵۰ و ViT-B/۱۶ مقایسه‌ی تاب آوری
تحلیل عدم توافق کلاس به کلاس در طبقه‌بندی بیماری‌های گیاهی**

نام استاد: دکتر هادی فراهانی

نام دستیار: آقای مبین نثاری

نام دانشجو: ناهید حاتمی بلاسی

شماره دانشجویی: ۴۰۴۴۲۲۲۰۷

تابستان ۱۴۰۵

مقدمه :

در سال‌های اخیر، تشخیص بیماری‌های گیاهی از روی تصویر به یکی از کاربردهای مهم یادگیری عمیق در کشاورزی هوشمند تبدیل شده است؛ چون می‌تواند با کاهش خطای انسانی، تسریع فرایند پایش و کمک به تصمیم‌گیری به‌موقع، از افت عملکرد محصولات جلوگیری کند. با ظهور Vision Transformer (ViT) این پرسش مطرح شده که آیا self-attention سراسری می‌تواند در چنین مسئله‌ای بر استخراج ویژگی‌های محلی شبکه‌های کانولوشنی (CNN) برتری داشته باشد و اگر آری، این برتری از کجا ناشی می‌شود. واقعیت این است که مقایسه‌ی صرف کدام مدل دقت بالاتری دارد پاسخ کاملی به این پرسش نمی‌دهد؛ برای رسیدن به درکی عمیق‌تر باید بررسی کرد که هر مدل واقعاً به کدام بخش از تصویر تکیه می‌کند.

۱. مسئله و هدف پژوهش

در این پژوهش، مسئله‌ی اصلی، فاین‌تیون کردن یک مدل مبتنی بر Vision Transformer برای طبقه‌بندی بیماری برگ گیاهان است. به این منظور، یک مدل ViT پیش‌آموزش‌دیده (ViT-B/16) و در کنار آن یک شبکه‌ی CNN هم‌رده (ResNet-50) روی یک اسپلیت یکسان از داده و با بودجه‌ی آموزشی برابر (matched training budget) فاین‌تیون می‌شوند، تا بتوان رفتار هر دو رویکرد را به‌صورت منصفانه با هم مقایسه کرد. هدف این نیست که فقط ببینیم کدام مدل بهتر است بلکه یک مشارکت اصیل هم طراحی کرده‌ایم و با شواهد کمی بررسی و دفاع می‌کنیم. این مشارکت به‌جای روش کلیشه‌ای مقاومت در برابر خرابی تصادفی کل تصویر که در آزمایش‌های robustness زیاد استفاده می‌شود، آزمایشی را انتخاب کرده که ارتباط مستقیم‌تری با خود مسئله دارد یعنی پوشاندن کنترل‌شده‌ی بخشی از ناحیه‌ی علامت بیماری روی برگ و بررسی این‌که هر مدل تا چه حد می‌تواند بیماری را صرفاً از روی بقیه‌ی برگ و زمینه تشخیص دهد. علاوه بر آزمایش اصلی occlusion، این پژوهش سه بررسی مکمل را نیز پوشش می‌دهد که شامل تحلیل عدم‌توافق کلاس‌ها بین دو مدل و کاوش تفسیرپذیری (تولید نقشه‌های attention rollout در برابر Grad-CAM) و سنجش کارایی داده (بررسی accuracy در برابر اندازه‌ی مجموعه‌ی آموزشی) است.

۲. داده پژوهش

۱.۲ مجموعه داده

مجموعه‌ی داده PlantVillage مورد استفاده قرار گرفته است که اولین بار در مقاله‌ی Mohanty و همکاران (۲۰۱۶) معرفی شده است. در این پروژه از نسخه‌ی BrandonFors/Plant-Diseases-PlantVillage-Dataset روی Hugging Face Hub استفاده شده که در واقع یک بازتاب از داده‌ی اصلی با ساختار درست و قابل استفاده است. این مجموعه شامل ۵۴'۳۰۵ تصویر برگ در ۳۸ کلاس که شامل بیماری‌های مختلف روی محصولات گوناگون به‌همراه کلاس‌های سالم است. داده‌ها از ابتدا به دو بخش train/test تقسیم شده‌اند (به‌ترتیب حدود ۴۳'۵۰۰ و ۱۰'۸۰۰ تصویر). دلیل عدم استفاده از داده اصلی مطابق مستندات کد (src/data.py)، مخزن اصلی mohanty/PlantVillage روی Hub به‌صورت خودکار به یک ستون رشته‌ای تکی (مثل path) تبدیل می‌شود و ستون‌های تصویر/برچسب decode شده را در اختیار نمی‌گذارد. بنابراین از این mirror استفاده کردیم که ستون‌های image و label را مستقیم در اختیار می‌گذارد.

جدول ۲- مشخصات کلی داده و زیر مجموعه استفاده شده

مورد	مقدار
نام دیتاست روی Hub	BrandonFors/Plant-Diseases-PlantVillage-Dataset
منبع اصلی	Mohanty, PlantVillage و همکاران (۲۰۱۶)
تعداد کل تصاویر	۵۴۳۰۵
تعداد کلاس‌ها	۳۸
تعداد تقریبی train / test	$10800 \approx / 43500 \approx$
زیرمجموعه‌ی استفاده‌شده (به‌علت محدودیت منابع)	حداکثر ۱۵۰ نمونه کلاس برای train و ۳۰ نمونه برای test

۲.۲ پیش‌پردازش

مهم‌ترین عوامل پیش‌پردازش شامل موارد زیر است:

۱. استفاده از نمونه‌گیری لایه‌ای (stratified) که با توجه به محدودیت زمان و GPU در Colab، نمیتوان از همه‌ی داده‌ها استفاده کرد. برای همین از هر کلاس حداکثر ۱۵۰ نمونه برای آموزش و ۳۰ نمونه برای آزمون انتخاب شد. این انتخاب به‌صورت تصادفی seed دار انجام شد تا نتایج قابل تکرار باشد و مهمتر از همه، توازن بین کلاس‌ها حفظ شود و هیچ کلاسی حذف یا تضعیف نشود.
۲. تقویت داده (augmentation) که برای آموزش، فقط از دو تبدیل ساده استفاده شد که شامل RandomHorizontalFlip و RandomResizedCrop. این یک رویکرد تقویتی سبک است که عمداً برای هر دو مدل یکسان نگه داشته شد تا هیچ برتری‌ای به نفع یکی از آنها ایجاد نشود.
۳. تبدیل‌های ارزیابی برای ارزیابی اما از هیچ تقویتی استفاده نشد؛ فقط Resize و CenterCrop اعمال شد. این کار باعث میشود سنجش نهایی کاملاً عادلانه و قابل مقایسه باشد.
۴. هر مدل نرمالسازی مخصوص به خودش را می‌خواهد. برای ViT، اندازه‌ی تصویر و میانگین/انحراف معیار نرمالسازی مستقیماً از پیکربندی مدل در timm (با resolve_data_config) خوانده شد تا دقیقاً با همان شرایطی که مدل هنگام پیش‌آموزش دیده بود هماهنگ باشد. ResNet-۵۰ هم از نرمال‌سازی استاندارد ImageNet روی تصاویر ۲۲۴×۲۲۴ استفاده می‌کند.
۵. استفاده از ماسک اکتشافی ناحیه‌ی بیماری (HSV) برای آزمایش اصلی این پژوهش یک پیش‌پردازش اضافه هم لازم است. ابتدا باید برگ را از پس‌زمینه جدا کنیم و سپس در فضای رنگی HSV، بافت سبز سالم را از ناحیه‌ی غیرسبز مشکوک به بیماری تفکیک کنیم. چون این بخش هسته‌ی مشارکت اصیل پژوهش است که در ادامه به آن پرداخته می‌شود.

۳. روش

۱.۳ خط لوله‌ی داده و آماده‌سازی داده

پیش از رسیدن به هر مدل، تصاویر خام باید به تانسورهای ورودی استاندارد تبدیل شوند، این کار در چند گام انجام می‌شود:

۱. استفاده از `load_plantvillage` که دیتاست را از Hugging Face میخواند و ستون‌های `image` و `label` را شناسایی میکند. یک مسیر پشتیبان دفاعی هم برای `Schema`های متفاوت در نظر گرفته شده تا کد در شرایط مختلف بدون وقفه کار کند.
۲. استفاده از `stratified_indices` برای هر کلاس، حداکثر `max_per_class` نمونه به صورت تصادفی `seed` دار انتخاب میکند. نکته‌ی مهم این است که در این مرحله هیچ تصویری واقعاً `decode` نمیشود و فقط از ستون `label` استفاده میشود؛ برای همین این بخش سریع و سبک است و توازن کلاسها هم حفظ می‌شود.
۳. استفاده از `make_transform` که تبدیل‌های `train` و `eval` را می‌سازد.
۴. استفاده از `build_resnet` و `build_vit` مدل‌ها را با وزن‌های پیش‌آموز شدید می‌سازند و لایه‌ی طبقه‌بندی نهایی را به ۳۸ کلاس تغییر می‌دهند.

۵. مدل‌ها

دو مدل با بودجه‌ی محاسباتی و تعداد `epoch` یکسان فایننتیون شده‌اند تا مقایسه کاملاً منصفانه باشد:

استفاده از `ViT-B/16` مدل `۱۶_۲۲۴_vit_base_patch` با وزن‌های پیش‌آموزش‌دیده‌ی `ImageNet` از کتابخانه‌ی `timm` (Wightman, ۲۰۱۹). تصویر ورودی به وصله‌های `۱۶×۱۶` تقسیم می‌شود، هر وصله به یک بردار نشانده (embedding) تبدیل می‌شود و سپس به همراه یک توکن `CLS` وارد `۱۲` بلوک `self-attention` سراسری میشود تا بازنمایی نهایی ساخته شود. قدرت اصلی این معماری این است که `self-attention` از همان لایه‌های ابتدایی میتواند وابستگی بین وصله‌های دور از هم را مدل کند (Dosovitskiy و همکاران، ۲۰۲۱).

استفاده `ResNet-50` مدل `resnet۵۰` با وزن‌های `IMAGENET۱K_V۲` از `torchvision` یک شبکه‌ی کانولوشنی عمیق `۵۰` لایه با بلوک‌های `residual` (He و همکاران، ۲۰۱۶) که میدان دریافت آن در لایه‌های اولیه محلی است و فقط با عمیق‌تر شدن شبکه به تدریج گسترش می‌یابد. در هر دو مدل، فقط لایه‌ی طبقه‌بندی نهایی جایگزین شده و کل شبکه (نه فقط لایه‌ی آخر) در طول فایننتیون به‌روزرسانی میشود. این یک انتخاب عمدی است تا مقایسه فقط به کدام `backbone` بهتر منتقل می‌شود محدود نشود.

۳. مشارکت خلاقانه

ایده‌ی خلاقانه‌ی این پژوهش، آزمایش انسداد هدفمند ناحیه‌ی بیماری (Targeted Symptom-Region Occlusion) است. نقطه‌ی شروع این ایده، یک پرسش ساده بود: به جای روش رایج خراب کردن تصادفی کل تصویر، برای سنجش `robustness` چه میشود اگر دقیقاً بخشی از خود لکه‌ی بیماری را بپوشانیم و ببینیم هر مدل چقدر میتواند از روی باقیمانده‌ی برگ (context) هنوز تشخیص درست بدهد؟ این پرسش از یک تفاوت معماری ناشی می‌شود که `self-attention` در `ViT` سراسری است و میتواند وصله‌های دور از هم برگ را به یکدیگر مرتبط کند، در حالی که میدان دریافت `CNN` محلی است. اگر این تفاوت معماری واقعاً تأثیرگذار باشد، باید در رفتار دو مدل وقتی سیگنال محلی بیماری ناقص میشود، خودش را نشان دهد. برای اینکه نتیجه قابل اطمینان باشد، به جای پوشاندن تصادفی کل تصویر، یک ماسک اکتشافی رنگی (heuristic HSV mask) ساخته شد که ناحیه‌ی غیرسبز برگ معمولاً محل لکه و زخم بیماری را از بافت سبز سالم جدا میکند. سپس دقیقاً به اندازه‌ی یکسان پیکسل از هر حالت یا

از مکان‌های تصادفی پوشانده می‌شود؛ به این ترتیب، هر افت دقتی که رخ دهد واقعاً به مکان حذف نسبت داده می‌شود و نه به تعداد پیکسل‌های حذف شده است.

۶. فرضیه‌های پژوهش

۶.۱ فرضیه اصلی:

با افزایش میزان انسداد ناحیه‌ی بیماری، دقت هر دو مدل افت می‌کند؛ اما چون ViT-B/۱۶ از self-attention سراسری استفاده میکند و میتواند وصله‌های دور از هم برگ را به یکدیگر مرتبط سازد، انتظار می‌رود افت دقتش کندتر از ResNet-۵۰ باشد، مدلی که به میدانهای دریافت محلی متکی است. این تفاوت به‌خصوص وقتی دیده می‌شود که تنها بخشی از علامت بیماری (در شدت‌های ۲۵٪ و ۵۰٪) پوشانده شود.

۶.۲ فرضیه‌های فرعی:

۶.۲.۱ فرضیه‌ی فرعی ۱ (اثر مکان انسداد):

اگر ماسک اکتشافی HSV واقعاً ناحیه‌ی بیماری را درست شناسایی کند، پوشاندن پیکسل‌های ناحیه‌ی disease باید افت دقت محسوس‌تری نسبت به پوشاندن همان تعداد پیکسل از ناحیه‌ی healthy یا از یک مکان کاملاً تصادفی (random) ایجاد کند، چون سیگنال تشخیصی اصلی دقیقاً از همان ناحیه می‌آید.

۶.۲.۲ فرضیه‌ی فرعی ۲ (نرخ افت نسبی ViT در برابر ResNet):

به لطف self-attention سراسری، انتظار می‌رود درصد افت نسبی دقت ViT نسبت به خط مبنایش، در شدتهای پایین انسداد (۲۵٪) کمتر از درصد افت نسبی ResNet باشد؛ یعنی ViT دیرتر شروع به افت می‌کند.

۶.۲.۳ فرضیه‌ی فرعی ۳ (الگوی خطاهای کلاس به کلاس):

در تحلیل عدم توافقی، انتظار می‌رود ViT بیشترین برتری را در کلاسهایی نشان دهد که علائم بیماریشان به صورت لکه‌های پراکنده و غیرمجاور روی برگ ظاهر می‌شود (مثل Early Blight یا Septoria) چون self-attention میتواند این الگوهای دور از هم را در یک نگاه سراسری به هم مرتبط کند، در حالی که کانولوشن محلی ResNet باید همین ارتباط را لایه به لایه و به‌کندی بسازد.

۷. پیکربندی آموزش

آموزش هر دو مدل با بهینه‌ساز AdamW (weight_decay=1e-۴) و نرخ یادگیری 3×10^{-5} انجام می‌شود و برنامه‌ی نرخ یادگیری CosineAnnealingLR در طول آموزش اعمال می‌گردد. حداکثر تعداد epoch برای مرحله‌ی اصلی برابر ۳ تعیین شد، دقیقاً یکسان برای هر دو مدل تا الزام بودجه‌ی آموزشی برابر (matched training budget) که در تعریف مسئله مطرح

شد، رعایت شود. اندازه‌ی batch هم برای هر دو مدل ۳۲ است. برای آزمایش مکمل کارایی داده از بودجه‌ی کوتاه‌تر epoch ۲ استفاده شده تا اجرا سریع‌تر تمام شود.

۲.۷ خطوط مبنای مقایسه

برای اینکه برتری هر معماری به‌درستی سنجیده شود، ساختار خط مبنا به‌صورت زیر تعریف شده است:

جدول ۳- خطوط مبنای مقایسه

خط مبنا	توصیف
ResNet-۵۰ (خط مبنای (CNN	دقیقاً همان بودجه، همان دیتالودر و همان معیارهای ViT فاین‌تیون شده تا تفاوت عملکرد صرفاً به تفاوت معماری نسبت داده شود.
original (بدون انسداد)	در آزمایش occlusion، دقت هر مدل روی تصویر دست‌نخورده به‌عنوان خط مبنای داخلی برای سنجش افت نسبی استفاده می‌شود.

۸. معیارهای ارزیابی

برای آموزش اصلی دو معیار accuracy و Macro-F^۱ روی مجموعه‌ی تست گزارش می‌شود. گزارش Macro-F^۱ در کنار accuracy یک انتخاب عمده است؛ چون با ۳۸ کلاس، اگر کلاس‌ها کاملاً متوازن نباشند، accuracy به‌تنهایی می‌تواند گمراه‌کننده باشد.

۸.۱ معیارهای آزمایش

در آزمایش اصلی پژوهش، دقت و Macro-F^۱ به‌ازای هر ترکیب مدل × شرط × شدت گزارش می‌شود، یعنی:

۱. ۲ مدل (ViT و ResNet)

۲. ۴ شرط (original / random / disease / healthy)

۳. ۳ شدت (۲۵٪ / ۵۰٪ / ۷۵٪)

علاوه بر عدد مطلق، افت نسبی هم محاسبه می‌شود (درصد افت نسبت به خط مبنای همان مدل) تا مقایسه‌ی دو مدل با خط مبنای متفاوت منصفانه باشد.

۸.۲ تحلیل عدم‌توافق

برای هر کلاس، شمار نمونه‌هایی که فقط ViT درست تشخیص داده در برابر نمونه‌هایی که فقط ResNet درست تشخیص داده محاسبه می‌شود، روی همان ترتیب ثابت داده (بدون shuffle) تا مقایسه‌ی نمونه‌به‌نمونه معتبر باشد.

برای اطمینان از تکرارپذیری دقیق، seed تصادفی ثابت ۴۲ در سراسر آزمایش‌ها (در numpy، random و torch) تنظیم شده تا خروجی در اجراهای مکرر یکسان بماند.

۳.۸ محیط اجرا

پیاپی‌سازیها روی Google Colab با GPU از نوع Tesla T۴ اجرا شده‌اند. برای بازتولیدپذیری کامل، نسخه‌های کتابخانه‌ها به صورت زیر پین شده‌اند:

جدول ۴- نسخه‌های کتابخانه‌ها

کتابخانه	نسخه
Torch	۲.۴.۱
Torchvision	۰.۱۹.۱
Timm	۱.۰.۹
Datasets	۲.۲۱.۰
opencv-python-headless	۴.۱۰.۰.۸۴
scikit-learn	۱.۵.۱
Pandas	۲.۲.۲
Numpy	۱.۲۶.۴
Matplotlib	۳.۹.۲


۹. نتایج

جدول ۵- نتایج آموزش در epoch ۳

مدل	Epoch	Train Loss	Val Accuracy	Val Macro-F۱
ViT-B/۱۶	۱	۰.۵۰۶۸	۹۸.۱۶٪	۹۸.۱۵٪
ViT-B/۱۶	۲	۰.۰۳۲۲	۹۸.۵۱٪	۹۸.۴۹٪
ViT-B/۱۶	۳	۰.۰۰۷۰	۹۸.۹۵٪	۹۸.۹۴٪
ResNet-۵۰	۱	۳.۰۷۹۳	۷۳.۷۷٪	۷۲.۲۱٪
ResNet-۵۰	۲	۱.۲۹۱۹	۸۷.۸۱٪	۸۷.۱۹٪
ResNet-۵۰	۳	۰.۷۸۷۷	۸۸.۶۰٪	۸۸.۱۵٪

نتایج آموزش با بودجه کاملاً برابر، تفاوت چشمگیری در رفتار دو معماری نشان می‌دهد. مدل ViT-B/۱۶ از همان اولین epoch با دقت ۹۸.۱۶ درصد وارد می‌شود و با شیبی ملایم به ۹۸.۵۱ و سپس ۹۸.۹۵ درصد در پایان epoch سوم می‌رسد، به‌طوریکه ResNet-۵۰ از ۷۳.۷۷ درصد شروع می‌کند و با یک جهش بزرگ در epoch دوم به ۸۷.۸۱ درصد میرسد و نهایتاً در epoch سوم به ۸۸.۶۰ درصد می‌رسد؛ به این ترتیب اختلاف نهایی حدود ۱۰.۳۵ واحد درصد به نفع ViT ثبت می‌شود. این الگو نشان می‌دهد که برتری ViT صرفاً به همگرایی سریع‌تر محدود نیست، بلکه از همان ابتدا ویژگی‌های ImageNet را به مراتب بهتر به دامنه PlantVillage منتقل می‌کند، در حالی که ResNet در همین بودجه کوتاه هنوز در حال سازگار شدن با دامنه جدید است. از سوی دیگر، کاهش شدید Train Loss و بولت به ۰.۰۰۷ (عملاً صفر) نشان‌دهنده ظرفیت بالای مدل در حفظ داده‌های آموزشی است که با توجه به داده کم هر کلاس (۱۵۰ نمونه) و مدل ۸۶ میلیون پارامتری قابل انتظار است؛ اما از آنجا که Validation Accuracy همچنان در حال

افزایش است، این پدیده به **overfitting** مخرب تبدیل نشده و صرفاً باید در تفسیر نتایج محتاط بود. نزدیکی کامل **accuracy** و **Macro** در **F1** هر دو مدل نیز تایید میکند که نمونه‌گیری لایه‌ای توازن کلاسها را به خوبی حفظ کرده و معیار **accuracy** در اینجا گمراه‌کننده نیست. این نتایج زمینه مناسبی برای آزمایش انسداد هدفمند فراهم میکنند، زیرا اگر **ViT** با این دقت بالا و اقعا به بازنمایی سراسری تکیه کند، انتظار میرود افت دقت آن زیر انسداد ناحیه بیماری کندتر از **ResNet** باشد؛ هرچند باید در بحث **Limitations** صادقانه اشاره کرد که بودجه سه **epoch** برای **ResNet** کوتاه بوده و ممکن است بخشی از این فاصله به عدم بلوغ کامل آن نسبت داده شود.



شکل ۱- دقت اعتبارسنجی و **Macro-F1** در سه **epoch**

نمودارهای روند **Validation Accuracy** (سمت چپ) و **Validation Macro-F1** (سمت راست) در شکل ۱، به خوبی رفتار متفاوت دو معماری را در طول فرآیند بهینه‌سازی به تصویر می‌کشند. اولین نکته برجسته در این شکل، موازی بودن و رفتار کاملاً یکسان هر دو نمودار است؛ نزدیکی منحنی دقت و شاخص **Macro-F1** در تمام نقاط برای هر دو مدل نشان می‌دهد که توزیع پیش‌بینی‌ها روی کلاس‌های مختلف متوازن بوده و ارزیابی مدل‌ها تحت تاثیر چالش عدم توازن کلاس‌ها قرار نگرفته است. این موضوع نشان‌دهنده موفقیت نمونه‌گیری لایه‌ای در حفظ توازن توزیع داده‌هاست. بررسی جزئی‌تر رفتار مدل‌ها تفاوت آشکاری را در سرعت همگرایی و نقطه شروع نشان می‌دهد. مدل **ViT-B/16** (منحنی نارنجی) از همان انتهای **Epoch** اول در لبه بالایی نمودار (بالای ۹۸ درصد) قرار گرفته و در دو گام بعدی نیز با شیبی بسیار ملایم و با ثبات، روند صعودی خود را تا مرز ۹۹ درصد ادامه می‌دهد. در مقابل، مدل **ResNet-50** (منحنی آبی) در اولین ارزیابی با دقت پایین‌تر از ۷۵ درصد کار خود را آغاز می‌کند، اما در گام دوم جهش ناگهانی و بزرگی را ثبت کرده و به مرز ۸۸ درصد نزدیک می‌شود و پس از آن در گام سوم به یک فاز تثبیت نسبی (پلاتو) با شیب بسیار کم وارد می‌شود. این تفاوت رفتار در نمودار اثبات می‌کند که ویژگی‌های استخراج‌شده توسط مکانیسم **self-attention** سراسری در معماری **ViT**، از قبل انطباق بسیار بالایی با ویژگی‌های بافت برگ و علائم بیماری داشته‌اند و مدل بدون نیاز به طی کردن دوره‌های آموزشی طولانی، با کمترین تغییر در بازنمایی‌ها به کارایی بهینه رسیده است. از سوی دیگر، شیب تند تغییرات **ResNet-50** بین گام اول و دوم نشان‌دهنده پویایی بیشتر این مدل برای یادگیری و تنظیم فیلترهای محلی خود با شرایط دامنه جدید است. این تحلیل تصویری، فرضیه تفاوت ساختاری در انتقال‌پذیری دو مدل را تایید کرده و بستر مناسبی را برای تفسیر نتایج آزمایش انسداد در گام‌های بعدی فراهم می‌کند.

کلاس	فقط ViT درست	فقط ResNet درست
Tomato — Early Blight	۲۰	۰
Tomato — Late Blight	۱۱	۲
Tomato — Healthy	۱۱	۰
Tomato — Septoria Leaf Spot	۹	۰
Pepper Bell — Bacterial Spot	۸	۰
Tomato — Spider Mites	۷	۰
Tomato — Bacterial Spot	۷	۰
Corn — Northern Leaf Blight	۶	۰
Tomato — Target Spot	۶	۰
Potato — Late Blight	۴	۰


تحلیل نمونه‌به‌نمونه پیش‌بینی‌ها روی ۱۱۴۰ داده تست نشان‌دهنده یک عدم‌تقارن چشمگیر است؛ به طوری که در ۱۲۲ نمونه فقط ViT-B/۱۶ درست عمل کرده و در مقابل تنها در ۴ نمونه ResNet-۵۰ موفق به تشخیص صحیح شده است که این نسبت تقریبی ۳۰ به ۱ برتری قاطع ترنسفورمر را نشان می‌دهد. با بررسی ۱۰ کلاس برتر جدول عدم‌توافق، مشخص می‌شود که بیشترین اختلاف در کلاس‌هایی مانند Tomato Early Blight با ۲۰ نمونه اختلاف، Tomato Late Blight (با ۱۱ نمونه) و Septoria Leaf Spot (با ۹ نمونه) رخ داده است؛ بیماری‌هایی که علائم آن‌ها به صورت لکه‌های ریز، متعدد، نامنظم و پراکنده روی برگ ظاهر می‌شوند. مکانیسم self-attention سراسری در ViT به خوبی می‌تواند ارتباط بین این علائم پراکنده را در کل تصویر مدل‌سازی کند، در حالی که فیلترهای محلی CNN در ResNet-۵۰ برای ارتباط دادن این نقاط دور از هم به لایه‌های عمیق‌تر نیاز دارند و در بودجه آموزشی محدود، در تفکیک این لکه‌ها از بافت سالم برگ یا پس‌زمینه دچار خطا می‌شوند. علاوه بر این، اختلاف ۱۱ نمونه‌ای در کلاس Tomato Healthy نشان می‌دهد که ViT در شناسایی برگ‌های کاملاً سالم و بدون علامت نیز دقیق‌تر است و کمتر دچار مثبت کاذب می‌شود، که این نتایج در مجموع فرضیه برتری معماری سراسری ViT در شناسایی الگوهای پراکنده را تایید می‌کند.

نتایج تحلیل عدم توافق تا حدی با فرضیه فرعی سوم همخوانی دارد، زیرا بیشترین برتری ViT در کلاس‌هایی مانند Early Blight، Septoria Leaf Spot، Spider Mites و Bacterial Spot مشاهده شده است که نشانه‌های بیماری در آنها معمولاً به صورت لکه‌های ریز، متعدد و پراکنده روی سطح برگ ظاهر می‌شوند. این الگو نشان می‌دهد که self-attention سراسری احتمالاً به ViT کمک کرده است تا ارتباط میان بخش‌های دور از هم تصویر را بهتر در نظر بگیرد؛ با این حال، صرف مشاهده این برتری برای اثبات رابطه علی کافی نیست و باید در کنار نتایج تفسیرپذیری و آزمایش انسداد بررسی شود. برای این منظور، نقشه Attention Rollout مدل ViT و Grad-CAM مدل ResNet-۵۰ برای چهار تصویر نمونه تولید شد، اما چون فایل خروجی در بسته‌نهایی نتایج موجود نبود، امکان مقایسه مستقیم نواحی مورد توجه دو مدل در این گزارش وجود ندارد و نتیجه‌گیری درباره تفاوت الگوهای توجه باید با احتیاط انجام شود.

جدول ۷- نتایج کامل آزمایش


مدل	شرط	شدت	دقت	Macro-F1
ViT	original	۰٪	۹۸.۰۸٪	۰.۹۷۹
ViT	random	۲۵٪	۹۷.۱۲٪	۰.۹۶۹
ViT	random	۵۰٪	۹۴.۲۳٪	۰.۹۰۹
ViT	random	۷۵٪	۸۳.۶۵٪	۰.۸۱۱
ViT	disease	۲۵٪	۹۶.۱۵٪	۰.۹۵۹
ViT	disease	۵۰٪	۹۳.۲۷٪	۰.۹۲۶
ViT	disease	۷۵٪	۸۷.۵۰٪	۰.۸۰۴
ViT	healthy	۲۵٪	۹۱.۳۵٪	۰.۸۸۹
ViT	healthy	۵۰٪	۸۳.۶۵٪	۰.۷۹۸
ViT	healthy	۷۵٪	۷۴.۰۴٪	۰.۶۴۲
ResNet	original	۰٪	۸۱.۷۳٪	۰.۷۷۴
ResNet	random	۲۵٪	۷۵.۰۰٪	۰.۶۹۲
ResNet	random	۵۰٪	۶۰.۵۸٪	۰.۵۳۵
ResNet	random	۷۵٪	۵۵.۷۷٪	۰.۵۱۴
ResNet	disease	۲۵٪	۸۳.۶۵٪	۰.۸۰۴
ResNet	disease	۵۰٪	۷۷.۸۸٪	۰.۷۱۷
ResNet	disease	۷۵٪	۷۶.۹۲٪	۰.۷۲۹
ResNet	healthy	۲۵٪	۷۱.۱۵٪	۰.۶۸۵
ResNet	healthy	۵۰٪	۵۹.۶۲٪	۰.۴۹۳
ResNet	healthy	۷۵٪	۵۲.۸۸٪	۰.۴۳۳

نتایج ارزیابی مدل‌ها تحت آزمایش انسداد هدفمند (جدول فوق)، یافته‌های بسیار غیرمنتظره و مهمی را درباره نحوه تصمیم‌گیری این دو معماری آشکار می‌سازد. بر خلاف فرضیه اولیه که انتظار داشت انسداد ناحیه بیماری (Disease Occlusion) بیشترین آسیب را به عملکرد مدل‌ها بزند، نتایج نشان داد که در هر دو مدل، انسداد بافت سالم برگ (Healthy) مخرب‌ترین سناریو بوده است؛ به طوری که در شدت انسداد ۷۵ درصد، دقت ViT در شرط بافت سالم به ۷۴.۰۴ درصد و دقت ResNet به ۵۲.۸۸ درصد افت می‌کند، در حالی که در شرط انسداد بیماری، دقت‌ها به ترتیب در سطح بالای ۸۷.۵۰ درصد و ۷۶.۹۲ درصد حفظ می‌شوند. این رفتار نشان می‌دهد که هر دو معماری برای تشخیص نوع بیماری، به جای تمرکز صرف روی خود لکه‌ها، به شدت به ویژگی‌های زمینه یعنی بافت سالم اطراف لکه (مانند رنگ رگبرگ‌ها، ساختار برگ و پس‌زمینه) تکیه می‌کنند. با این حال، تفاوت کلیدی دو معماری در میزان تاب‌آوری آن‌هاست؛ ViT-B/۱۶ در تمامی شروط و شدت‌های انسداد، افت دقت بسیار ملایم‌تری را نسبت به ResNet-۵۰ تجربه می‌کند. این پایداری بالاتر ViT، به ویژه در شرایط انسداد شدید، تاییدکننده فرضیه اصلی پژوهش است؛ مکانیسم self-attention سراسری در ViT به مدل اجازه می‌دهد تا با وجود حذف بخش‌های زیادی از تصویر، همچنان ارتباط بین بخش‌های باقیمانده را حفظ کرده و تصمیم درستی اتخاذ کند، در حالی که ResNet-۵۰ به دلیل تکیه بر فیلترهای محلی، با از دست رفتن بخش‌های کلیدی تصویر دچار فروپاشی عملکردی شدیدتری می‌شود؛ تا جایی که در مسدودسازی ۷۵ درصد بافت سالم، دقت آن به نزدیکی سطح حدس تصادفی افت می‌کند.



شکل ۲ - دقت هر مدل در چهار شرط، برحسب شدت انسداد

نمودار در شکتب ۲، مقایسه‌ای عملکرد مدل‌ها نشان می‌دهد که تغییر در یکپارچگی ساختاری تصویر، تأثیر متفاوتی بر کارایی هر دو معماری دارد؛ با این حال، برتری مطلق پایداری ViT-B/۱۶ نسبت به ResNet-۵۰ در تمامی سناریوها مشهود است. در هر دو مدل، انسداد بافت سالم برگ (منحنی نارنجی) بیشترین آسیب عملکردی را به همراه داشته است که نشان‌دهنده تکیه اساسی هر دو معماری به ویژگی‌های زمینه‌ای و بستر برگ برای تشخیص کلاس بیماری است؛ هرچند که ResNet در انسداد ۷۵ درصدی بافت سالم با افت شدید دقت به حدود ۵۰ درصد دچار فروپاشی ساختاری می‌شود، در حالی که ViT در همین شرایط دقت خود را بالای ۷۰ درصد حفظ می‌کند. علاوه بر این، در مدل ViT منحنی انسداد تصادفی (سبز) و انسداد ناحیه بیماری (آبی) رفتاری بسیار نزدیک به یکدیگر نشان می‌دهند که تأییدکننده توزیع یکنواخت و سراسری توجه مدل به کل تصویر است، در حالی که در ResNet، انسداد تصادفی آسیب بسیار بیشتری نسبت به انسداد متمرکز بیماری وارد می‌کند و حساسیت شدید این مدل بر پایه CNN را به تغییرات ساختاری محلی به تصویر می‌کشد.



شکل ۳ — افت دقت مطلق نسبت به خط مبنا، فقط برای شرط disease

نمودار میزان افت دقت نسبت به خط مبنا در سناریوی انسداد ناحیه بیماری، تفاوت بنیادین در نحوه مواجهه دو معماری با نویز و اطلاعات محلی را آشکار می‌سازد. در مدل ResNet-۵۰، انسداد ۲۵ درصدی ناحیه بیماری منجر به ثبت یک افت منفی (حدود

۲- درصد) می‌شود که به معنای افزایش دقت مدل نسبت به حالت بدون انسداد است؛ این رفتار پارادوکسیکال نشان می‌دهد که مدل در حالت عادی بر روی ویژگی‌های محلی نویزگونه و گمراه‌کننده در ناحیه بیماری متمرکز بوده و حذف فیزیکی این بخش‌ها با کاهش نویزهای مزاحم، تصمیم‌گیری مدل را بهبود بخشیده است. در نقطه مقابل، منحنی مدل ViT-B/۱۶ روندی کاملاً صعودی، یکنواخت و منطقی را طی می‌کند که نشان می‌دهد این مدل از ابتدا بر روی ویژگی‌های کلیدی و واقعی متمرکز بوده و با افزایش تدریجی انسداد، به شکلی کاملاً پیش‌بینی‌پذیر با از دست رفتن اطلاعات مفید مواجه شده است. این مقایسه ثابت می‌کند که معماری مبتنی بر self-attention به دلیل نگاه سراسری، درک بسیار پایدارتر و تفسیرپذیرتری از ویژگی‌های هدف ارائه می‌دهد، در حالی که معماری CNN به شدت تحت تأثیر نوسانات و نویزهای محلی قرار دارد.


در کمال تعجب و برخلاف فرضیه اولیه‌ای که داشتیم، آزمایش‌ها نشان داد که مسدود کردن ناحیه بیماری (Disease)، کمترین آسیب را به عملکرد مدل‌ها می‌زند. در واقع، حذف کردن لکه‌های بیماری برای هر دو مدل، بسیار کم‌هزینه‌تر از حذف کردن بافت سالم برگ یا حتی بخش‌های تصادفی تصویر بوده است. برای مثال، در مدل ResNet با شدت انسداد ۷۵٪، دقت مدل در شرط بیماری روی ۷۶.۹٪ باقی ماند، در حالی که در شرایط مشابه برای بافت سالم و انسداد تصادفی، دقت به ترتیب به ۵۲.۹٪ و ۵۵.۸٪ سقوط کرد. این آمار به وضوح نشان می‌دهد که حذف ناحیه بیماری، عملاً بی‌ضررترین نوع مداخله در تصویر بوده است. برای توجیه این نتیجه‌ی جالب، دو دلیل علمی محتمل وجود دارد. اولین محدودیت‌های فنی ماسک است از آنجا که در این پژوهش، هر پیکسل «غیرسبز» به عنوان بیماری علامت‌گذاری شد (Disease Mask)، احتمالاً بخش‌هایی از رگبرگ‌ها یا سایه‌های طبیعی برگ نیز به اشتباه در دسته بیماری قرار گرفته‌اند و مدل در واقع بخش‌هایی را از دست داده که برای تشخیص، حیاتی نبودند. دومین وابستگی به کل‌نگری (Holistic Context) که این نتیجه تأیید می‌کند که مدل‌های ما (چه CNN و چه ViT) برای تشخیص بیماری، به بافت و شکل کلی برگ (زمینه) به اندازه‌ی خود لکه بیماری تکیه دارند. در واقع، بافت سالم برگ حاوی اطلاعات زمینه‌ای آنقدر مهمی است که حذف آن، مدل را در درک ساختار تصویر دچار سردرگمی شدید می‌کند. موضوعی که نشان می‌دهد هوش مدل، در گرو درک کل تصویر است نه صرفاً نقاط کانونی بیماری باشد.

جدول ۸- دقت آزمون در برابر اندازه‌ی داده‌ی آموزشی

مدل	نمونه در هر کلاس	دقت	Macro-F1
ViT-B/۱۶	۲۰	۸۸.۸۶٪	۰.۸۸۸
ResNet-۵۰	۲۰	۱۱.۱۴٪	۰.۰۸۴
ViT-B/۱۶	۵۰	۹۶.۹۳٪	۰.۹۶۹
ResNet-۵۰	۵۰	۲۸.۵۱٪	۰.۲۶۲
ViT-B/۱۶	۱۰۰	۹۸.۸۶٪	۰.۹۸۹
ResNet-۵۰	۱۰۰	۶۶.۶۷٪	۰.۶۳۵
ViT-B/۱۶	۱۵۰	۹۹.۰۴٪	۰.۹۹۰
ResNet-۵۰	۱۵۰	۸۰.۲۶٪	۰.۷۹۱

بر اساس ۸، نتایج حاصل از ارزیابی مدل‌ها در برابر تغییرات حجم داده‌های آموزشی (جدول ۷)، تفاوت فاحش دو معماری را در کارآمدی نمونه‌ها (Data Efficiency) و قابلیت انتقال دانش به تصویر می‌کشد. در سناریوی محدودیت شدید داده (۲۰ نمونه در هر کلاس)، مدل ResNet-۵۰ با ثبت دقت ۱۱.۱۴٪ و شاخص Macro-F1 معادل ۰.۰۸۴ عملاً عملکردی نزدیک به حدس تصادفی ارائه می‌دهد، در حالی که ViT-B/۱۶ با همان حجم داده به دقت خیره‌کننده ۸۸.۸۶٪ دست می‌یابد که نشان‌دهنده توانایی استثنایی مکانیسم توجه سراسری در بهره‌گیری از وزن‌های پیش‌آموزش دیده است. با افزایش حجم داده‌ها به ۵۰ نمونه در هر کلاس،

ViT به سرعت به مرز اشباع عملکردی (۹۶.۹۳٪) نزدیک می‌شود، در حالی که روند بهبود در ResNet بسیار تدریجی و داده‌محور است؛ به طوری که حتی با افزایش داده‌ها به ۱۵۰ نمونه، دقت ResNet (معدل ۸۰.۲۶٪) همچنان با اختلاف معناداری پایین‌تر از عملکرد ViT با تنها ۲۰ نمونه قرار می‌گیرد. این رفتار ثابت می‌کند که معماری ViT به عنوان گزینه‌ای به مراتب بهینه‌تر و اقتصادی‌تر در سناریوهای عملی با محدودیت داده عمل می‌کند و شاخص متوازن Macro-F₁ آن نیز پایداری بالای این مدل را در تمامی کلاس‌ها، بدون دچار شدن به سوگیری‌های رایج در داده‌های کم، تأیید می‌نماید.



شکل ۴ — دقت آزمون در برابر اندازه‌ی داده‌ی آموزشی

شکل ۴ به‌خوبی نشان می‌دهد که با افزایش اندازه‌ی داده‌ی آموزشی، عملکرد هر دو مدل بهتر می‌شود، اما سرعت و کیفیت این بهبود در دو معماری کاملاً متفاوت است. مدل ViT-B/۱۶ از همان ابتدا، حتی با کمترین حجم داده، عملکرد بسیار بالایی دارد؛ به‌طوری‌که با فقط ۲۰ نمونه در هر کلاس، دقت آن به ۸۸.۹٪ و مقدار Macro-F₁ به حدود ۰.۸۹ می‌رسد. در مقابل، ResNet-۵۰ در همین شرایط تنها ۱۱.۱٪ دقت و ۰.۰۸۴ Macro-F₁ ثبت می‌کند که نشان می‌دهد تقریباً در سطح حدس تصادفی عمل کرده است. با بیشتر شدن داده‌ها، عملکرد ResNet به تدریج بهتر می‌شود، اما همچنان فاصله قابل توجهی با ViT حفظ می‌شود؛ به‌طوری‌که حتی در ۱۵۰ نمونه در هر کلاس نیز دقت ResNet هنوز ۱۸.۸ واحد درصد کمتر از ViT است. همچنین نمودار Macro-F₁ همین الگو را تأیید می‌کند و نشان می‌دهد برتری ViT فقط به دقت کلی محدود نیست، بلکه این مدل در سطح کلاس‌ها نیز عملکردی متوازن‌تر و پایدارتر دارد. در مجموع، این شکل به‌روشنی نشان می‌دهد که پیش‌آموزش ViT توانسته نمایش‌های عمومی‌تر و قابل‌انتقال‌تری برای مسئله تشخیص بیماریان گیاهان فراهم کند؛ به همین دلیل این مدل حتی در شرایط داده‌کم نیز بسیار مؤثرتر از ResNet عمل می‌کند.

۸. تحلیل انتقادی، محدودیت‌ها و صداقت علمی

۱.۸ تقابل فرضیه و واقعیت تجربی

در طراحی اولیه این پژوهش، فرضیه اصلی ما این بود که مدل ViT-B/۱۶ به دلیل بهره‌مندی از مکانیسم self-attention سراسری، در مواجهه با انسدادهای موضعی در ناحیه بیماری، افت دقت کندتر و پایداری بیشتری نسبت به ResNet-۵۰ نشان خواهد داد. با این حال، نتایج تجربی نشان داد که این فرضیه تنها به صورت جزئی و مشروط تأیید می‌شود. همچنین در ابعاد مطلق، ViT در تمام شرایط عملکرد بسیار قوی‌تری نسبت به ResNet داشت (به طوری که در بدترین حالت انسداد، دقت ۸۷.۵٪ را ثبت کرد که همچنان از دقت ۷۶.۹٪ ResNet بالاتر بود). همچنین در شدت انسداد پایین (۲۵٪)، افت نسبی ViT بسیار ناچیز (حدود

۱.۹۷٪) بود که فرضیه مقاومت آن را تأیید می‌کرد. اما با افزایش شدت انسداد به ۷۵٪، الگو معکوس شد و نرخ افت نسبی ViT (معادل ۱۰.۷۸٪) از ResNet (معادل ۵.۹۰٪) پیشی گرفت. علاوه بر این، برخلاف تصور اولیه ما، هر دو مدل به حذف بافت سالم برگ حساسیت بیشتری نشان دادند تا حذف خود ناحیه بیماری؛ یافته‌ای که فرض ساده‌انگارانه اولیه ما را به چالش می‌کشد. البته در این میان، تحلیل عدم‌توافق کلاس به کلاس، بخش دیگری از فرضیه ما را به شدت تقویت کرد؛ چرا که برتری چشمگیر ViT دقیقاً در کلاس‌هایی با علائم پراکنده و غیرمجاور (مانند Early Blight) متمرکز بود؛ یعنی همان جایی که انتظار می‌رفت مکانیسم توجه سراسری بتواند ارتباطات دوربرد پیکسل‌ها را به خوبی کشف کند.

۲.۸ محدودیت‌های پژوهش

برای توجیه این رفتارهای غیرمنتظره و حفظ صداقت علمی پژوهش، باید به چند عامل فنی، ساختاری و محدودیت‌های اجرایی اشاره کنیم:

۱. **محدودیت ماسک اکتشافی بیماری:** ماسک مورد استفاده بر پایه الگوریتم HSV طراحی شده بود و صرفاً «هر پیکسل غیرسبز روی برگ» را به عنوان بیماری تشخیص می‌داد. این یعنی رگبرگ‌ها، سایه‌ها یا حاشیه‌های طبیعی برگ نیز به اشتباه مسدود شده‌اند و لزوماً تمام پیکسل‌های مسدود شده مربوط به بافت خود بیماری نبوده‌اند. این محدودیت، علت اصلی حساسیت بیشتر مدل‌ها به حذف بافت به ظاهر سالم است. همچنین باید توجه داشت که شرط «Healthy» در این آزمایش، به معنای بافت سبز باقی‌مانده در یک برگ بیمار است، نه یک کلاس کاملاً سالم و مجزا.
۲. **پدیده سقف عملکردی (Ceiling Effect) در ViT:** از آنجا که نقطه شروع ViT بسیار بالا و نزدیک به سقف (۹۸٪) است، هر خطا یا نمونه اشتباه جدید، سهم درصدی بزرگ‌تری در محاسبه افت نسبی ایفا می‌کند و این موضوع معکوس شدن شیب افت در شدت ۷۵٪ را بدون ضعیف بودن واقعی مدل توضیح می‌دهد.
۳. **اندازه کوچک نمونه تست انسداد:** آزمایش انسداد به دلیل محدودیت‌های پردازشی روی ۱۰۴ تصویر انجام شد. این حجم کم نمونه باعث می‌شود برخی نوسانات (مانند بهبود عملکرد ۲ درصدی ResNet در انسداد ۲۵٪) بیشتر جنبه نویز آماری داشته باشند تا یک رفتار واقعی پایدار.
۴. **محدودیت‌های سخت‌افزاری و زمانی:** به دلیل محدودیت GPU در محیط گوگل کولب، مدل‌ها به جای کل مجموعه ۵۴ هزار تایی PlantVillage، روی زیرمجموعه‌ای محدود (حداکثر ۱۵۰ نمونه در هر کلاس) و تنها در ۳ اپوک آموزش دیدند.
۵. **نقش پررنگ بافت زمینه (Context):** نتایج به وضوح نشان دادند که هر دو معماری برای تصمیم‌گیری به شدت به بافت کلی برگ وابسته‌اند و فرضیه اولیه که مدل‌ها را تک‌بعدی و متمرکز بر یک منبع سیگنال خاص فرض می‌کرد، ساده‌انگاری بوده است.

۹. نتیجه‌گیری نهایی پژوهش

این پژوهش با مقایسه تطبیقی و تحت بودجه آموزشی برابر دو مدل ViT-B/۱۶ و ResNet-۵۰ روی مجموعه داده PlantVillage، و با طراحی یک آزمایش نوآورانه «انسداد هدفمند» در سه سناریوی مختلف، تلاش کرد تا تفاوت‌های معماری محلی و سراسری را آشکار کند.


یافته نهایی ما نشان داد که فرضیه برتری مقاومت ViT در برابر انسداد موضعی، تنها به صورت مشروط برقرار است. در واقع، برتری چشمگیر ViT بیشتر ناشی از قدرت فوق‌العاده آن در بازنمایی ویژگی‌ها (Representation) و کارایی بسیار بالا در سناریوهای کم‌داده (Data Efficiency) است، نه یک مقاومت ساختاری خاص در برابر حذف فیزیکی لکه‌های بیماری. با این حال، تحلیل‌های کلاس‌به‌کلاس به خوبی اثبات کردند که در کلاس‌هایی با علائم پراکنده، مکانیسم توجه سراسری همچنان یک مزیت رقابتی بی‌بدیل به این معماری می‌بخشد. این نتیجه‌گیری واقع‌بینانه، درک دقیق‌تر و صادقانه‌تری از رفتار این دو مدل در کاربردهای واقعی کشاورزی هوشمند به دست می‌دهد.

۱۰. پاسخ به سوالات بحث و مشاهدات

۱.۱۰ کانولوشن ماهیتی موضعی دارد و نسبت به انتقال، هم‌وردایی نشان می‌دهد؛ در حالی که خودتوجهی ماهیتی سراسری دارد. یک معماری هیبریدی طراحی کنید که در آن سازوکار توجه به یک شبکه CNN افزوده شود (یا به‌صورت معکوس، عمل کانولوشن به یک ViT تزریق شود) یک معماری هیبریدی طراحی کنید که در آن سازوکار توجه به یک شبکه CNN افزوده شود (یا به‌صورت معکوس، عمل کانولوشن به یک ViT تزریق شود). آیا ماژول توجه را در لایه‌های ابتدایی شبکه قرار می‌دهید یا در لایه‌های انتهایی، و دلیل شما چیست؟ پیش‌بینی می‌کنید این طراحی چه تغییری در ویژگی‌های آموخته‌شده مدل ایجاد کند؟

اگر بخواهیم یک معماری هیبریدی بین CNN و ViT طراحی کنیم، منطقی‌تر این است که attention را در لایه‌های عمیق‌تر و نزدیک به انتهای شبکه قرار دهیم، نه در همان لایه‌های ابتدایی. دلیلش این است که لایه‌های اولیه کانولوشنی در استخراج ویژگی‌های ساده و محلی مثل لبه‌ها، رنگ، بافت و مرز لکه‌ها بسیار کارآمد، کم‌هزینه و مناسب هستند و لازم نیست از همان ابتدا هزینه‌ی بالای self-attention را به مدل تحمیل کنیم. از طرف دیگر، نتایج همین پژوهش نشان داد که مزیت اصلی ViT در شناسایی الگوهای دیده می‌شود که علامت بیماری به صورت لکه‌های پراکنده و غیرمجاور در بخش‌های مختلف برگ ظاهر می‌شود؛ بنابراین attention زمانی بیشترین فایده را دارد که ابتدا ویژگی‌های محلی توسط چند لایه کانولوشنی استخراج شده باشند و سپس در مراحل عمیق‌تر، ارتباط بین این نواحی دور از هم برقرار شود. از نظر محاسباتی هم این انتخاب منطقی‌تر است، چون هزینه‌ی self-attention با تعداد توکن‌ها به‌صورت شدیدی افزایش پیدا می‌کند و اگر این عملیات روی نقشه‌های ویژگی کوچک‌تر در لایه‌های انتهایی انجام شود، مدل هم سبک‌تر می‌ماند و هم مؤثرتر عمل می‌کند. در نتیجه انتظار می‌رود چنین مدل هیبریدی در لایه‌های عمیق خود، به جای یادگیری صرفاً ویژگی‌های محلی، بازنمایی‌هایی بسازد که بتوانند چند ناحیه پراکنده ولی مرتبط را به‌صورت یک الگوی معنادار کنار هم قرار دهند. به‌طور خاص، پیش‌بینی می‌شود این معماری در کلاس‌هایی مثل Early Blight یا Septoria که ResNet خالص در آن‌ها ضعیف‌تر بود، عملکردی نزدیک‌تر به ViT داشته باشد.

۲.۱۰ نقشه‌های توجه ViT و نقشه‌های فعال‌سازی / گراد-کم CNN را برای یک تصویر یکسان، در کنار یکدیگر قرار دهید. هر یک از این نقشه‌ها ظاهراً بر چه نواحی یا الگوهای متمرکز هستند و آیا تفاوت مشاهده‌شده با شهود شما درباره نحوه دیدن تصویر توسط این دو مدل همخوانی دارد؟



شکل ۵- مقایسه‌ی بصری نقشه‌های توجه ViT و ResNet Grad-CAM

در مقایسه‌ی بصری نقشه‌های توجه استخراج‌شده از ViT و نقشه‌های Grad-CAM مربوط به ResNet، مشاهده می‌شود که ViT تصویر را به شکلی پخش‌تر و چندکانونی‌تر پردازش می‌کند، در حالی که ResNet بیشتر بر نواحی محدود و فشرده تمرکز دارد. در نقشه‌های ViT، توجه تنها به لکه‌ی بیماری محدود نمی‌ماند و علاوه بر ناحیه‌ی اصلی آسیب‌دیده، به حاشیه‌های برگ، بافت کلی و حتی بخش‌هایی از پس‌زمینه نیز وزن داده می‌شود؛ این رفتار نشان می‌دهد که ViT برای تصمیم‌گیری به روابط سراسری و context تصویر تکیه می‌کند. در مقابل، Grad-CAM مربوط به ResNet معمولاً تمرکزی موضعی‌تر و متمرکزتر بر مرکز

لکه‌ی بیماری یا ناحیه‌ی بافتی برجسته دارد که با ماهیت کانولوشن‌های محلی و ساختار سلسله‌مراتبی CNN ها همخوان است. این تفاوت تا حد زیادی با شهود نظری ما سازگار است؛ با این حال، نتایج آزمایش‌های occlusion نشان می‌دهد که این تمایز به‌صورت مطلق نیست. برای مثال، افت عملکرد نسبتاً کم ViT در پوشاندن ناحیه‌ی بیماری نشان می‌دهد که تصمیم این مدل فقط به یک نقطه‌ی خاص وابسته نیست، بلکه بر شواهد پراکنده در بخش‌های مختلف تصویر استوار است. از سوی دیگر، ResNet نیز صرفاً روی لکه‌ی بیماری قفل نشده و از بافت کلی برگ و ساختار زمینه‌ای آن نیز استفاده می‌کند. بنابراین، هرچند ViT به‌طور کلی دیدی سراسری‌تر و ResNet دیدی محلی‌تر دارد، اما هر دو مدل در عمل از context تصویر برای تصمیم‌گیری بهره می‌برند.

منابع:

- [۱] Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al. (۲۰۲۱). An Image is Worth ۱۶x۱۶ Words: Transformers for Image Recognition at Scale. International Conference on Learning Representations (ICLR).
- [۲] He, K., Zhang, X., Ren, S., & Sun, J. (۲۰۱۶). Deep Residual Learning for Image Recognition. IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
- [۳] Vaswani, A., Shazeer, N., Parmar, N., et al. (۲۰۱۷). Attention Is All You Need. Advances in Neural Information Processing Systems (NeurIPS) ۳۰.
- [۴] Selvaraju, R. R., Cogswell, M., Das, A., et al. (۲۰۱۷). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. IEEE International Conference on Computer Vision (ICCV).
- [۵] Abnar, S., & Zuidema, W. (۲۰۲۰). Quantifying Attention Flow in Transformers. Proceedings of the ۵۸th Annual Meeting of the Association for Computational Linguistics (ACL).
- [۶] Mohanty, S. P., Hughes, D. P., & Salathé, M. (۲۰۱۶). Using Deep Learning for Image-Based Plant Disease Detection. Frontiers in Plant Science, ۷, ۱۴۱۹. DOI: ۱۰.۳۳۸۹/fpls.۲۰۱۶.۰۱۴۱۹.
- [۷] Srinivas, A., Lin, T.-Y., Parmar, N., et al. (۲۰۲۱). Bottleneck Transformers for Visual Recognition (BoTNet). IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
- [۸] Wightman, R. (۲۰۱۹). PyTorch Image Models (timm) [Software library]. GitHub. <https://github.com/huggingface/pytorch-image-models>
- [۹] Paszke, A. et al. (۲۰۱۹). PyTorch: An Imperative Style, High-Performance Deep Learning Library. Advances in Neural Information Processing Systems (NeurIPS).
- [۱۰] Hugging Face Hub Dataset: BrandonFors/Plant-Diseases-PlantVillage-Dataset. <https://huggingface.co/datasets/BrandonFors/Plant-Diseases-PlantVillage-Dataset>